Dr. G. Eichner Math. Inst. JLU Gießen

Übungen zu R1: Grundlagen der Datenanalyse mit R Blatt 3

SoSe 2024 2. 5. 2024 Abgabe: \leq 15. 5. 2024, 14:00 Uhr

- 1. Zur Untersuchung eines möglichen Zusammenhangs zwischen der Tumorätiologie (= Tumorursache) von Spinaltumoren und der Blutgruppe wurden an 324 Patienten die entsprechenden Ausprägungen der beiden Merkmale registriert. In Stud.IP finden Sie die Datei Spinaltumoren.R, die ein R-Skript enthält, das diese Daten bereitstellt. Kopieren Sie sich diese Datei ("außerhalb" von R) in Ihr eigenes Arbeitsverzeichnis und öffnen Sie sie in einem Ihnen genehmen R-Editor!
 - a) Erzeugen Sie mithilfe des in Spinaltumoren.R befindlichen R-Codes zwei geeignete Faktorvektoren, die die Daten über Tumorätiologie und Blutgruppe enthalten!
 - b) Lassen Sie die eindimensionalen Absoluthäufigkeitsverteilungen der beiden Merkmale sowie ihre gemeinsame (= zweidimensionale = bivariate) Absoluthäufigkeitsverteilung bestimmen! Tun Sie dies auch für die korrespondierenden relativen Häufigkeiten!
 - c) Ergänzen Sie die Häufigkeitstabellen um nützliche Marginalien!
 - d) Leiten Sie aus dem Blutgruppen-Faktorvektor einen Faktorvektor ab, in dem die Blutgruppen A, B und AB zu Non-0 zusammengefasst sind und fassen Sie in der Tumorätiologie die Levels Nervenscheiden und Neuroepithelial zu Nervensystem entsprechend zusammen! Wiederholen Sie sodann mit den neuen Faktorvektoren die Teilaufgaben b) und c)!
- 2. Zu einem Datensatz z_1, \ldots, z_n soll die Matrix aller "Jackknife-Samples" erzeugt werden. Sie ist dadurch definiert, dass sie in ihrer *i*-ten Zeile das sogenannte "*i*-te Jackknife-Sample" $z_1, \ldots, z_{i-1}, z_{i+1}, \ldots, z_n$ (dem also das *i*-te Datum fehlt) enthält. Vorschlag zur Vorgehensweise:
 - a) Verwenden Sie als z-Sample der Einfachheit und Übersichtlichkeit halber die Zahlen $1, 2, \ldots, n$ mit n = 10 und erstellen Sie zunächst eine $(n \times n)$ -Matrix, die in jeder Zeile den vollständigen Datenvektor enthält!
 - b) Erzeugen Sie dann daraus die Matrix der Jackknife-Samples, indem Sie durch geeignetes eventuell trickreiches Umstrukturieren und Indizieren der Matrix die Hauptdiagonale gewissermaßen "herausschneiden"!
- 3. In Stud.IP finden Sie die Datei Europa.R. Kopieren Sie sich diese Datei ("außerhalb" von \mathbf{R}) in Ihr eigenes Arbeitsverzeichnis und öffnen Sie sie in einem Ihnen genehmen Editor! Sie enthält ein \mathbf{R} -Skript mit Informationen über verschiedenste Kennzahlen von 33 europäischen Staaten.
 - a) Erzeugen Sie mithilfe des in Europa. R befindlichen R-Codes und den dortigen Informationen eine Matrix, die die Daten über die europäischen Länder derart enthält, dass pro Zeile ein Land steht und in den Spalten die Kennzahlen!

- b) Versehen Sie die Zeilen der Matrix mit den jeweiligen Landesnamen und die Spalten mit (sinnhafteren als den in Europa.R verwendeten) Bezeichnungen für die in ihnen aufgeführten Kennzahlen!
- 4. Bereiten Sie die Informationen der Matrix aus Aufgabe 3 wie folgt auf:
 - a) Erstellen Sie eine Version der Matrix, deren Zeilen (Länder) nach dem BIP in Euro aufsteigend sortiert sind!
 - b) Ermitteln Sie aus den Länderdaten in den Spalten der Matrix (also nicht mithilfe der anfänglichen (Rohdaten-)Vektoren) sinnvolle (!) Gesamt- oder Durchschnittswerte, die für die gesamten europäischen Länder gelten, sofern möglich! Fügen Sie diese "zusammenfassenden" Informationen schießlich als eine neue, erste Zeile zur Matrix hinzu. Benennen Sie diese Zeile entsprechend!
 - c) Errechnen Sie das Pro-Kopf-BIP in Euro aus den Daten der Matrix und erweitern Sie die Matrix um eine zusätzliche Spalte mit dieser Information neben der Spalte des BIPs in Euro! Benennen Sie diese neue Spalte mit "ProKopfBIP"!