Dr. G. Eichner Math. Inst. JLU Gießen

Übungen zu R1: Grundlagen der Datenanalyse mit R Blatt 6

SoSe 2024 23. 5. 2024 Abgabe: \leq 5. 6. 2024, 14:00 Uhr

- 1. (Modifikation von Aufgabe 3 auf Blatt 5.) Zur Arbeitsweise von read.table:
 - a) Lesen Sie die kopierte Datei SMSA aus Ihrem Arbeitsverzeichnis nun mit Hilfe der Funktion read.table in einen Data Frame namens SMSA.df erneut ein, und zwar so, dass die Spalte ID der SMSA-Identifikationscodes zur Zeilenbenennung und nicht als Datenspalte verwendet wird!
 - b) Benennen Sie die Spalten (= Variablen) des Data Frames SMSA.df (analog zu Aufgabe 3e auf Blatt 5) mit kurzen, aber sinnvollen und ihrer Bedeutung entsprechenden Namen!
 - c) Führen Sie für SMSA.df die analogen Schritte der Aufgaben 3f bis 3h auf Blatt 5 durch!
- 2. (Fortsetzung von Aufgabe 1.) Univariate, grafische explorative Analyse (EDA) der SMSA-Daten: Überlegen Sie sich eine (oder mehrere) grafische Darstellungsmethode(n), mit der (oder denen) die Verteilungen der
 - a) Anzahlen der praktizierenden Ärzte und Ärztinnen,
 - b) Prozentsätze an High-School-AbsolventInnen und
 - c) privaten Gesamteinkommen

nach geografischen Regionen aufgeteilt geeignet und sinnvoll (!) veranschaulicht werden können! Erstellen Sie die Grafiken mithilfe der Formelvariante(n) der von Ihnen ggf. verwendeten Grafikfunktion(en) (oder zur Not alternativ mithilfe der Funktion split)!

- 3. Kopieren Sie sich die Datei MietenFrankfurt aus Stud.IP in Ihr eigenes, übliches R-Arbeitsverzeichnis und lesen Sie sie geeignet in R ein!
 - a) Fertigen Sie mit stem ein "stem-and-leaf"-Diagramm für diese Daten an! Probieren Sie die Wirkung des Arguments scale aus, indem Sie es mit (wenigen) Werten kleiner und größer als 1 versehen!
 - b) Führen Sie Analoges mit flächennormierten (!) Histogrammen für diese Daten durch, indem Sie das Argument breaks von hist zunächst nicht verwenden, dann nur die eine oder andere natürliche Zahl zwischen 4 und 40 an breaks übergeben (und dadurch die ungefähre Anzahl der äquidistanten Intervalle, in die die "Mietskala", sprich x-Achse eingeteilt werden soll, steuern) sowie schließlich verschiedene, auch irreguläre Gitter an breaks in Form eines Vektors zuweisen!
 - c) Experimentieren Sie entsprechend mit der Implementation des Kern-Dichteschätzers durch density (in Kombination mit plot wie in §4.2.2), indem Sie zunächst kein weiteres Argument von density verwenden und dann für ihr Argument bw (wie "bandwidth") wenige verschiedene Werte zwischen 25 und 400 ausprobieren! Wie hängt das qualitative Aussehen, konkret die "Glattheit" des Graphen des Kern-Dichteschätzers von der "bandwidth" tendenziell ab?